

BÁO CÁO BÀI 1

HIỂU DỮ LIỆU, CHỌN DỮ LIỆU VÀ TIỀN XỬ LÝ

Đề tài: Phân tích hành vi và mức độ gắn kết của người xem livestream

Dataset: KuaiLive

Nội dung: Đề xuất + Ma trận + Điều tra tiền xử lý

1. GIỚI THIỆU DỮ LIỆU

KuaiLive là bộ dữ liệu thực tế về hoạt động livestream, gồm thông tin người dùng, streamer, phòng livestream và các sự kiện tương tác như click, comment, like, gift và negative feedback. Trong Bài 1, nhóm xây dựng bộ dữ liệu phân tích ở mức người xem – livestream gồm 20.000 bản ghi và 30 thuộc tính.

1.1. Mục tiêu

- Xác định cấu trúc, kiểu dữ liệu và ý nghĩa thuộc tính.
- Kiểm tra dữ liệu thiếu, trùng lặp và giá trị bất thường.
- Đánh giá phân phối của các thuộc tính hành vi.
- Đề xuất phương án tiền xử lý phù hợp.
- Tạo dữ liệu biến đổi, chuẩn hóa và rời rạc hóa phục vụ các bài toán tiếp theo.

2. ĐIỀU TRA VÀ KHẢO SÁT DỮ LIỆU

2.1. Kích thước dữ liệu

Bộ dữ liệu phân tích có 20.000 dòng và 30 thuộc tính, gồm nhóm định danh, nhân khẩu học, thông tin tài khoản, hành vi xem, hành vi tương tác và các biến dẫn xuất về mức độ gắn kết.

STT	Thuộc tính	Ý nghĩa
1	Viewer ID	Định danh người xem
2	Live ID	Định danh livestream
3	Streamer ID	Định danh streamer
4	Viewer Age	Tuổi người xem
5	Viewer Gender	Giới tính người xem
6	Viewer Country	Quốc gia người xem
7	Viewer Device Brand	Thương hiệu thiết bị
8	Viewer Device Price	Mức giá thiết bị
9	Account Age Days	Số ngày tuổi tài khoản
10	Accumulated Watch Count	Số lần xem tích lũy
11	Accumulated Watch Duration	Thời lượng xem tích lũy
12	Is Live Streamer	Có phải streamer hay không
13	Is Photo Author	Có phải photo author hay không
14	Watch Time	Thời gian xem livestream
15	Click Count	Số lần click/xem
16	Comment Count	Số lượt bình luận
17	Like Count	Số lượt thích
18	Gift Count	Số lượt tặng quà
19	Gift Value	Giá trị quà tặng
20	Has Comment	Có bình luận hay không
21	Has Like	Có like hay không
22	Has Gift	Có tặng quà hay không
23	Interaction Count	Tổng comment + like + gift
24	Like Rate	Tỷ lệ like theo thời gian xem
25	Comment Rate	Tỷ lệ comment theo thời gian xem
26	Gift Rate	Tỷ lệ gift theo thời gian xem
27	Engagement Score	Điểm mức độ gắn kết
28	Engagement Level	Low/Medium/High
29	Streamer Gender	Giới tính streamer
30	Streamer Age	Tuổi streamer

3. MA TRẬN TIỀN XỬ LÝ DỮ LIỆU

Ma trận tổng hợp thuộc tính, vấn đề cần kiểm tra, phương án xử lý và mục đích sử dụng.

Nhóm	Thuộc tính	Kiểu	Vấn đề	Xử lý	Mục đích
Định danh	Viewer_ID, Live_ID, Streamer_ID	ID	Kiểm tra khóa trùng	Giữ nguyên, không chuẩn hóa	Xác định thực thể
Nhân khẩu học	Viewer_Age, Gender, Country	Số/Categorical	Missing, kiểu dữ liệu	Giữ số; mã hóa categorical khi cần	Đặc trưng người xem
Thiết bị	Device_Brand, Device_Price	Categorical/Số	Missing, thang đo	Giữ; chuẩn hóa khi dùng ML	Đặc trưng người dùng
Tài khoản	Account_Age_Days, Accumulated_*	Số	Khác thang đo, lệch phải	Kiểm tra; log/standardize khi phù hợp	Hành vi nền
Hành vi xem	Watch_Time	Số	Lệch mạnh, giá trị lớn	$\ln(x+1)$, sau đó chuẩn hóa khi cần	Giảm ảnh hưởng giá trị lớn
Tương tác	Click/Comment/Like/Gift_Count	Count	Nhiều số 0; IQR có thể = 0	Không xóa giá trị dương	Giữ thông tin tương tác
Giá trị quà	Gift_Value	Số	Rất nhiều số 0, lệch phải	Giữ 0; phân mức khi cần	Phân tích đóng góp
Nhị phân	Has_Comment, Has_Like, Has_Gift	Binary	Kiểm tra nhất quán với count	Giữ 0/1	Luật kết hợp
Dẫn xuất	Interaction_Count, các Rate	Số	Khác thang đo	Tính từ dữ liệu; chuẩn hóa khi cần	Đo cường độ
Gắn kết	Engagement_Score/Level	Số/Categorical	Kiểm tra phân phối	Giữ score; chia mức	Mô tả gắn kết
Streamer	Streamer_Gender, Streamer_Age	Categorical/Số	Kiểu dữ liệu	Giữ; mã hóa/chuẩn hóa khi cần	Đặc trưng streamer

4. ĐIỀU TRA TIỀN XỬ LÝ

4.1. Dữ liệu thiếu

Kết quả kiểm tra trên bộ dữ liệu 20.000×30 cho thấy không có ô dữ liệu bị bỏ trống. Vì vậy tập hiện tại không cần thay thế missing. Nếu phát sinh missing, có thể dùng median cho biến số và mode cho biến phân loại; Gift_Value/Gift_Count chỉ quy về 0 khi xác định ô trống mang nghĩa không phát sinh quà.

4.2. Dữ liệu trùng lặp

Khóa Viewer_ID + Live_ID + Streamer_ID được dùng để kiểm tra trùng ở cấp người xem – livestream. Kết quả: không phát hiện khóa trùng trong 20.000 bản ghi; không xóa bản ghi.

4.3. Ngoại lệ

Thuộc tính	Kết quả	Hiện tượng	Số bản ghi	Quyết định
Watch_Time	Q1 1.743,75; Q3 23.265,25; IQR 21.521,50	Ngưỡng trên 55.547,50	3.258	Không xóa; log transform
Click_Count	Q1=1; Q3=1; IQR=0	>1	2.227	Không xóa; do phân phối tập trung
Comment_Count	Q1=0; Q3=0; IQR=0	>0	712	Không xóa; là hành vi
Like_Count	Q1=0; Q3=0; IQR=0	>0	771	Không xóa; là hành vi
Gift_Count	Q1=0; Q3=0; IQR=0	>0	284	Không xóa; là hành vi
Gift_Value	284 bản ghi >0; max=284	Nhiều giá trị 0	—	Giữ 0; phân mức

Các giá trị bị IQR đánh dấu không mặc nhiên là lỗi. Với các biến count có IQR bằng 0, mọi giá trị dương có thể bị đánh dấu nhưng lại mang ý nghĩa thực tế, vì vậy nhóm không xóa máy móc các quan sát này.

4.4. Gift_Value

Tổng Gift_Value là 18.870; có 284 bản ghi phát sinh quà; giá trị lớn nhất là 284. Giá trị trung bình của các bản ghi Gift_Value > 0 khoảng 66,44366. Do có nhiều số 0, nhóm giữ nguyên số 0 và tạo biến phân mức giá trị quà.

5. ĐỀ XUẤT PHƯƠNG ÁN TIỀN XỬ LÝ

5.1. Xử lý phân phối lệch

Đề xuất biến đổi Watch_Time bằng $\ln(x+1)$ để giảm độ lệch và ảnh hưởng của các giá trị rất lớn nhưng vẫn giữ thông tin quan sát.

5.2. Chuẩn hóa

Đối với biến số dùng cho học máy, đề xuất StandardScaler sau các biến đổi cần thiết. ID và categorical không chuẩn hóa như biến liên tục.

5.3. Rời rạc hóa

Tạo Like_Behavior, Comment_Behavior và Gift_Behavior với trạng thái có/không. Gift_Value được chia No_Gift, Low_Gift và High_Gift.

5.4. Xử lý ngoại lệ

Không xóa máy móc outlier; ưu tiên log-transform/chuẩn hóa. Chỉ loại khi có bằng chứng xác định dữ liệu lỗi.

6. KẾT QUẢ SAU TIỀN XỬ LÝ

Hạng mục	Kết quả	Ý nghĩa
Kích thước	20.000×30	Đạt yêu cầu nền dữ liệu
Missing	0 ô trống	Không cần thay thế
Trùng khóa	Không phát hiện	Không xóa
Watch_Time	Có giá trị lớn/lech	Tạo $\text{Log_Watch_Time} = \ln(\text{Watch_Time}+1)$
Like_Behavior	771 bản ghi có like	No_Like/Liked
Comment_Behavior	712 bản ghi có comment	No_Comment/Commented
Gift_Behavior	284 bản ghi có gift	No_Gift/Gifted
Gift_Value_Level	Ngưỡng tham chiếu $\approx 66,44366$	No_Gift/Low_Gift/High_Gift
Engagement_Level	Low 6.666; Medium 6.667; High 6.667	Phân bố cân bằng theo quantile

7. KẾT LUẬN

Bài 1 đã hoàn thành quá trình hiểu dữ liệu, lựa chọn bộ dữ liệu và xây dựng quy trình tiền xử lý cho đề tài phân tích hành vi và mức độ gắn kết của người xem livestream. Bộ dữ liệu 20.000 bản ghi và 30 thuộc tính tạo nền tảng cho các bài toán phân lớp, luật kết hợp và gom cụm.

Kết quả điều tra cho thấy dữ liệu hiện tại không có missing và không phát hiện khóa trùng. Các biến hành vi có tính thừa và lệch mạnh, đặc biệt Watch_Time và Gift_Value. Nhóm lựa chọn hướng xử lý giữ lại các quan sát hợp lệ, log-transform thời gian xem, chuẩn hóa biến số khi cần và rời rạc hóa một số hành vi để phục vụ luật kết hợp.

Lưu ý: trước khi nộp, cần đối chiếu các số liệu trong báo cáo với kết quả chạy cuối cùng của khảo sát.ipynb.