

BÁO CÁO THỰC HÀNH KHAI PHÁ DỮ LIỆU

BÀI 2 – PHÂN LỚP (CLASSIFICATION)

Đề tài: Dự đoán mức độ gắn kết (Engagement_Level) của người xem livestream KuaiLive

Học phần: Khai phá dữ liệu (Data Mining) | Nhóm: Nhóm 4

1. GIỚI THIỆU DỮ LIỆU

- Tên bộ dữ liệu:** KuaiLive Viewer Engagement Dataset (Processed).
- Nguồn gốc:** Bộ dữ liệu thực tế về hoạt động phát sóng trực tiếp (livestream) trên nền tảng Kuaishou do nhóm nghiên cứu công bố.
- Quy mô dữ liệu:** Gồm 20.000 bản ghi tương ứng với 20.000 phiên tương tác của người xem. Sau khi phân tách 80% cho tập huấn luyện (Train) và 20% cho tập kiểm thử (Test), tập Test bao gồm đúng 4.000 bản ghi.
- Biến mục tiêu:** Engagement_Level đại diện cho mức độ gắn kết của người xem, bao gồm 3 lớp phân loại: High (Gắn kết cao), Medium (Gắn kết trung bình), và Low (Gắn kết thấp).
- Lý do dataset phù hợp với bài toán phân lớp:** Dữ liệu ở Bài 2 đã có sẵn nhãn phân lớp định trước (Engagement_Level). Việc áp dụng học có giám sát (Supervised Learning) giúp xây dựng mô hình tự động dự báo mức độ gắn kết của người xem mới dựa trên các đặc trưng hành vi tương tác trong phiên livestream.

2. TIỀN XỬ LÝ DỮ LIỆU VÀ PHẠM VI

- Loại bỏ các thuộc tính định danh:** Loại bỏ các cột khóa thực thể bao gồm Viewer_ID, Live_ID, và Streamer_ID ra khỏi tập đặc trưng X để tránh hiện tượng học vẹt các thông tin định danh cá nhân.
- Phân tách tập dữ liệu (Train/Test Split):** Thực hiện phân chia dữ liệu theo tỷ lệ 80% Train (16.000 mẫu) và 20% Test (4.000 mẫu) sử dụng phương pháp phân tầng stratify=y với random_state=42. Tỷ lệ các lớp trong tập Test đảm bảo tính cân bằng: High (1.334 mẫu), Low (1.333 mẫu), và Medium (1.333 mẫu).
- Xử lý đặc trưng số (Numeric Features):** Áp dụng SimpleImputer(strategy="median") để điền khuyết giá trị thiếu bằng trung vị, sau đó chuẩn hóa bằng StandardScaler() về phân phối chuẩn $N(0, 1)$.
- Xử lý đặc trưng hạng mục (Categorical Features):** Áp dụng SimpleImputer(strategy="most_frequent") điền khuyết bằng giá trị xuất hiện nhiều nhất, sau đó mã hóa biến giả bằng OneHotEncoder(handle_unknown="ignore").

- **Đóng gói Pipeline chống rò rỉ dữ liệu:** Toàn bộ quá trình tiền xử lý được tích hợp trong ColumnTransformer và Pipeline, đảm bảo các thông số chuẩn hóa chỉ được học trên tập Train và biến đổi độc lập trên tập Test.

3. THUẬT TOÁN VÀ PHƯƠNG PHÁP HUẤN LUYỆN

3.1. Thuật toán Logistic Regression

- **Cơ chế:** Giả định quan hệ giữa log-odds của các lớp mục tiêu và các đặc trưng đầu vào có dạng tuyến tính.
- **Cấu hình:** Sử dụng tham số `class_weight="balanced"` và `max_iter=2000` để tối ưu hóa quá trình hội tụ và hỗ trợ cân bằng trọng số giữa các lớp.
- **Đặc điểm:** Tốc độ tính toán nhanh, hỗ trợ xuất xác suất dự báo mịn, tuy nhiên khó nắm bắt các mối quan hệ phi tuyến phức tạp.

3.2. Thuật toán Decision Tree (Cây quyết định)

- **Cơ chế:** Phân chia dữ liệu dựa trên các quy tắc ngưỡng tối ưu hóa độ tinh khiết (Gini Impurity hoặc Entropy).
- **Cấu hình:** Áp dụng `class_weight="balanced"` và thiết lập `random_state=42`.
- **Đặc điểm:** Không yêu cầu giả định phân phối chuẩn hay tính tuyến tính, mô hình hóa tốt các tương tác phi tuyến.

3.3. Tối ưu hóa siêu tham số (GridSearchCV & Cross-Validation)

- **Phương pháp:** Sử dụng GridSearchCV kết hợp với StratifiedKFold(`n_splits=5`, `shuffle=True`, `random_state=42`) trên tập Train.
- **Độ đo tối ưu:** Đánh giá và lựa chọn cấu hình tốt nhất dựa trên chỉ số `f1_macro`.
- **Lưới siêu tham số:**
 - **Logistic Regression:** Thử nghiệm `C = [0.01, 0.1, 1, 10]`.
 - **Decision Tree:** Thử nghiệm `max_depth = [None, 4, 8, 12]`, `min_samples_leaf = [1, 5, 10]`, và `criterion = ['gini', 'entropy']`.

4. ĐÁNH GIÁ VÀ SO SÁNH CÁC MÔ HÌNH

Bảng tổng hợp kết quả đánh giá kỹ thuật của các mô hình trên tập kiểm thử Test (4.000 bản ghi):

Mô hình	CV macro- F1	Accuracy	Precision macro	Recall macro	F1 macro	Precision weighted	Recall weighted	F1 weighted
Decision Tree	0.9999	0.9998	0.9998	0.9997	0.9997	0.9998	0.9998	0.9997
Logistic Regression	0.9987	0.9980	0.9980	0.9980	0.9980	0.9980	0.9980	0.9980

Nhận xét:

- **Accuracy & Macro F1:** Cả hai mô hình đều đạt hiệu năng xuất sắc trên tập kiểm thử độc lập với các chỉ số vượt mức 99.8%.
- **So sánh:** Decision Tree đạt kết quả nhỉnh hơn Logistic Regression ở tất cả các chỉ số (Accuracy đạt 0.9998 so với 0.9980; CV macro-F1 đạt 0.9999 so với 0.9987).

5. MA TRẬN NHẦM LẤN VÀ ĐƯỜNG CONG ROC/AUC

5.1. Ma trận nhầm lẫn (Confusion Matrix)

- **Logistic Regression (Tổng 4.000 mẫu Test):**
 - Lớp High (1.334 mẫu): Dự đoán chính xác 1.333 mẫu, nhầm 1 mẫu sang Medium.
 - Lớp Low (1.333 mẫu): Dự đoán chính xác 1.332 mẫu, nhầm 1 mẫu sang Medium.
 - Lớp Medium (1.333 mẫu): Dự đoán chính xác 1.327 mẫu, nhầm 6 mẫu sang High.
- **Decision Tree (Tổng 4.000 mẫu Test):**
 - Lớp High (1.334 mẫu): Dự đoán chính xác 1.334 mẫu (Đạt 100%).
 - Lớp Low (1.333 mẫu): Dự đoán chính xác 1.332 mẫu, nhầm 1 mẫu sang Medium.
 - Lớp Medium (1.333 mẫu): Dự đoán chính xác 1.333 mẫu (Đạt 100%).

5.2. Đánh giá đường cong ROC và chỉ số AUC (One-vs-Rest)

Bảng chi tiết chỉ số ROC-AUC đa lớp theo chiến lược One-vs-Rest:

STT	Mô hình	ROC-AUC macro (OvR)	ROC-AUC weighted (OvR)
0	Logistic Regression	0.9998	0.9998
1	Decision Tree	0.9998	0.9998

Nhận xét về ROC/AUC:

- **Chiến lược đánh giá:** Do bài toán có 3 lớp mục tiêu (High, Medium, Low), nhóm áp dụng chiến lược One-vs-Rest (OvR) kết hợp mã hóa nhị phân label_binarize để tính đường cong ROC và diện tích dưới đường cong AUC.
- **Kết quả định lượng:** Cả hai mô hình Logistic Regression và Decision Tree đều đạt điểm ROC-AUC macro = 0.9998 và ROC-AUC weighted = 0.9998.
- **Độ phân tách:** Trên biểu đồ, đường TPR (True Positive Rate) vọt thẳng lên 1.0 ngay tại tỷ lệ FPR (False Positive Rate) tiệm cận 0. Điều này chứng tỏ cả hai mô hình có khả năng phân biệt hoàn hảo giữa các mức độ gắn kết của người xem mà gần như không gặp rủi ro báo động giả.

6. KẾT LUẬN

- **Tổng kết hiệu năng:** Bài thực hành số 2 đã ứng dụng thành công hai thuật toán Logistic Regression và Decision Tree vào bài toán phân lớp mức độ gắn kết người xem livestream KuaiLive. Cả hai mô hình đều đạt độ chính xác gần như tuyệt đối (>99.8%). Decision Tree được lựa chọn là mô hình tối ưu nhất nhờ Accuracy đạt 0.9998 và chỉ nhầm duy nhất 1 mẫu trên tổng số 4.000 mẫu kiểm thử.
- **Ý nghĩa ứng dụng:** Bộ đặc trưng tiền xử lý phản ánh chính xác ranh giới giữa các mức độ tương tác của người xem, giúp hệ thống livestream có thể phân loại người dùng theo thời gian thực để áp dụng các chiến lược gợi ý nội dung tối ưu.