

BÁO CÁO THỰC HÀNH KHAI PHÁ DỮ LIỆU

BÀI 4 – GOM CỤM (CLUSTERING)

Đề tài: Phân tích hành vi và mức độ gắn kết của người xem livestream KuaiLive

Học phần: Khai phá dữ liệu (Data Mining) | Nhóm: Nhóm 4

1. GIỚI THIỆU DỮ LIỆU

- Tên bộ dữ liệu: KuaiLive Viewer Engagement Dataset (Processed).
- Nguồn gốc: Bộ dữ liệu thực tế về hoạt động phát sóng trực tiếp (livestream) trên nền tảng Kuaishou do nhóm nghiên cứu công bố, bao gồm thông tin phòng phát sóng, người xem, streamer và các sự kiện tương tác.
- Quy mô dữ liệu: Đúng 20.000 bản ghi (mỗi dòng đại diện cho một phiên tương tác người xem – livestream) và 47 thuộc tính sau quá trình tiền xử lý ở Bài 1 (kể thừa từ 30 thuộc tính khảo sát ban đầu).
- Tập thuộc tính chính dùng cho gom cụm: Nhóm lựa chọn 6 thuộc tính hành vi tương tác cốt lõi đo lường cường độ tham gia của người xem trong phiên: Watch_Time (thời gian xem), Click_Count (lượt click), Comment_Count (bình luận), Like_Count (thả tim), Gift_Count (số lượt tặng quà) và Gift_Value (tổng giá trị quà tặng).
- Lý do dataset phù hợp với bài toán gom cụm: Trong môi trường livestream thực tế, người xem không hề có sẵn nhãn phân lớp định trước (bản chất của học không giám sát – Unsupervised Learning). Dữ liệu chứa các chiều đo lường hành vi phong phú, cho phép đo đạc khoảng cách hình học và mật độ để tự nhiên bóc tách các nhóm người xem có thói quen tiêu thụ nội dung khác biệt (nhóm xem lướt qua, nhóm click nhiều phòng, nhóm tương tác xã hội like/comment, và nhóm người ủng hộ VIP tặng quà giá trị cao).

2. TIỀN XỬ LÝ DỮ LIỆU

Quy trình tiền xử lý phục vụ gom cụm tuân thủ chặt chẽ các phát hiện từ Bài 1 và yêu cầu kỹ thuật của thuật toán dựa trên khoảng cách:


- Xử lý dữ liệu thiếu (Missing Values): Kết quả kiểm tra toàn diện trên 20.000 bản ghi cho thấy tập dữ liệu có 0 giá trị thiếu (tỷ lệ 0.0%). Toàn bộ các quan sát đều đầy đủ thông tin, không cần áp dụng thuật toán điền khuyết.
- Xử lý dữ liệu trùng lặp (Duplicates): Kiểm tra tính duy nhất theo bộ khóa định danh thực thể Viewer_ID + Live_ID + Streamer_ID ghi nhận 0 dòng trùng lặp, đảm bảo mỗi quan sát là một phiên tương tác độc lập.
- Xử lý ngoại lai (Outliers) và phân phối lệch: Khảo sát bằng IQR và boxplot cho thấy các biến tương tác (quà tặng, bình luận, like) có tính chất cực kỳ lệch phải (Right-skewed) với hơn 95% giá trị bằng 0. Nhóm quyết định không xóa bỏ máy móc các giá trị dương vì đây là hành vi tương tác tích cực thực tế. Thay vào đó, nhóm áp dụng phép biến đổi $\ln(x + 1)$ ($\log_{1p}$) nhằm thu hẹp phương sai, kéo giảm độ lệch đuôi dài mà vẫn bảo toàn thứ tự quan sát.
- Chuẩn hóa dữ liệu (Feature Scaling): Các biến số sau khi $\log_{1p}$ được chuẩn hóa bằng StandardScaler (Z-score) về phân phối chuẩn hóa có trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$. Việc chuẩn hóa giúp các thuộc tính có thang đo khác nhau không làm ảnh hưởng quá lớn đến khoảng cách giữa các điểm dữ liệu trong các thuật toán clustering dựa trên khoảng cách (Euclidean).
- Chọn thuộc tính gom cụm: Loại bỏ các khóa ID (Viewer_ID, Live_ID, Streamer_ID) do chỉ mang ý nghĩa định danh; loại bỏ nhãn mục tiêu phân lớp Engagement_Level và chỉ số tổng hợp Engagement_Score để tránh rò rỉ thông tin trong học không giám sát. Tập 6 đặc trưng chuẩn hóa cuối cùng đưa vào mô hình là: Z_Watch_Time, Z_Click_Count, Z_Comment_Count, Z_Like_Count, Z_Gift_Count, Z_Gift_Value.

3. THUẬT TOÁN K-MEANS

Cơ chế hoạt động của K-Means: K-Means là thuật toán gom cụm dựa trên phân vùng (partitioning). Cơ chế gồm 4 bước lặp: (1) Khởi tạo ngẫu nhiên K tâm cụm ban đầu (dùng thuật toán k-means++); (2) Gán mỗi điểm dữ liệu vào tâm cụm gần nhất dựa trên khoảng cách Euclidean; (3) Cập nhật lại vị trí tâm cụm bằng giá trị trung bình cộng (mean) tọa độ của các điểm thuộc cụm đó; (4) Lặp lại bước 2 và 3 cho đến khi vị trí tâm cụm không còn thay đổi đáng kể hoặc đạt số vòng lặp tối đa.

3.1. Xác định số cụm K bằng Elbow Method và Silhouette Score

Nhóm tiến hành thử nghiệm K-Means với số lượng cụm K chạy từ 2 đến 10 (tham số random_state=42, n_init=10), tính toán tổng bình phương khoảng cách trong cụm (Inertia/WCSS) và chỉ số Silhouette Score.



Hình 1. Phương pháp Elbow (WCSS) và Silhouette Score xác định số cụm K tối ưu

- Phương pháp Elbow: Quán tính (Inertia) giảm rất mạnh từ K = 2 (82.532,6) xuống K = 5 (36.197,5), sau đó tốc độ giảm chậm dần và đồ thị uốn thoải rõ rệt từ K = 5 trở đi. Dựa trên biểu đồ Elbow, nhóm lựa chọn K = 5.
- Phương pháp Silhouette Score: Ở K = 2, Silhouette đạt 0.8417 nhưng là do sự phân tách cực đoan (chỉ tách riêng 284 user tặng quà và dòn 19.716 user còn lại vào một nhóm duy nhất). Khi khảo sát phân cụm chi tiết, giá trị Silhouette đạt đỉnh cục bộ 0.6742 tại K = 5, cao hơn đáng kể so với K = 3 (0.6576) và K = 4 (0.6681). Sang K = 6, Silhouette sụt giảm xuống 0.6087.
- Kết quả K-Means với K = 5: Số cụm K = 5; Quán tính Inertia = 36.197,49; Silhouette Score = 0.6742; Davies-Bouldin Score = 0.7337. Mô hình phân chia 20.000 mẫu thành 5 nhóm có cấu trúc nén chặt và phân biệt rõ rệt.

4. THUẬT TOÁN CLUSTERING THỨ HAI (DBSCAN)

Nguyên lý DBSCAN: DBSCAN (Density-Based Spatial Clustering of Applications with Noise) là thuật toán gom cụm dựa trên mật độ. Thuật toán lan truyền các cụm qua các điểm lõi (core points) có ít nhất min_samples điểm lân cận nằm trong bán kính ϵ (eps). DBSCAN không giới hạn hình dạng cụm và tự động nhận diện các quan sát cô lập ở vùng mật độ thấp thành điểm nhiễu (Noise, nhãn -1).

Khảo sát siêu tham số: Nhóm thử nghiệm lưới tham số với ϵ trong [0.5, 0.8, 1.0, 1.2, 1.5] và min_samples trong [20, 50]:

- Khi $\epsilon = 0.5$: Số lượng điểm nhiễu cao (732 điểm, chiếm 3.7%), tách thành 6 cụm.
- Khi $\epsilon = 0.8$, min_samples = 50: Đạt cấu hình tối ưu nhất với 7 cụm mật độ, số điểm nhiễu được kiểm soát ở mức 641 điểm (3.20%). Silhouette Score trên các cụm lõi đạt 0.6586 và chỉ số Davies-Bouldin Score đạt 0.6012.
- Khi $\epsilon \geq 1.2$: Bán kính quá lớn khiến các cụm nhỏ bị sát nhập quá mức, làm giảm tính phân biệt.


5. ĐÁNH GIÁ VÀ SO SÁNH CÁC THUẬT TOÁN

Nhóm tổng hợp kết quả đánh giá kỹ thuật giữa hai mô hình clustering trên cùng tập dữ liệu chuẩn hóa:

Thuật toán	Tham số tối ưu	Số cụm	Số điểm nhiễu	Tỷ lệ nhiễu	Silhouette (↑)	Davies-Bouldin (↓)
K-Means	K = 5	5	0	0.0%	0.6742	0.7337
DBSCAN	eps=0.8, min_samples=50	7	641	3.20%	0.6586	0.6012

Nhận xét kỹ thuật:

- Ý nghĩa chỉ số: Silhouette Score (dao động [-1, 1]) càng cao thể hiện khoảng cách giữa các cụm càng lớn so với độ phân tán nội cụm. Davies-Bouldin Index (dao động [0, +∞)) càng thấp chứng tỏ tỷ lệ phân tán nội cụm trên khoảng cách tâm cụm càng nhỏ, chất lượng phân cụm càng tốt.
- So sánh định lượng: K-Means đạt Silhouette Score cao hơn (0.6742 so với 0.6586 của DBSCAN), chứng minh việc phân chia không gian lỗi bao phủ toàn diện đạt độ gắn kết nội cụm rất tốt. Ngược lại, DBSCAN đạt chỉ số Davies-Bouldin tốt hơn (0.6012 so với 0.7337) vì đã loại bỏ 641 điểm ngoại lai dị biệt vào tập nhiễu (Noise), giúp các cụm lõi có mật độ siêu tập trung.
- Kết luận lựa chọn: Về mặt kỹ thuật, K-Means (K = 5) là thuật toán phù hợp hơn cho bài toán phân khúc toàn diện người dùng vì nó phân loại chính xác 100% tập dữ liệu mà không bỏ sót bản ghi nào vào tập nhiễu.



Hình 2. Trực quan hóa cấu trúc phân cụm K-Means (có tâm cụm) và DBSCAN (có điểm Noise) qua không gian 2D PCA (giải thích 61.69% tổng phương sai)

6. PROFILING CÁC CỤM (ĐẶC TRƯNG HÓA K-MEANS K=5)

Dựa trên mô hình K-Means tối ưu (K = 5), nhóm thống kê các giá trị thực tế (trước chuẩn hóa) của 6 đặc trưng hành vi để xây dựng hồ sơ kỹ thuật cho từng cụm:

Cụm	Số mẫu	Tỷ lệ	Thời gian xem (s)	Lượt Click	Bình luận	Thả tim	Lượt quà	Giá trị quà
Cluster 0	1.882	9.41%	198.2 s	2.37	0.00	0.00	0.00	0.00
Cluster 1	16.824	84.12%	47.7 s	1.00	0.00	0.00	0.00	0.00
Cluster 2	284	1.42%	706.7 s	1.49	0.64	0.48	1.02	66.44
Cluster 3	466	2.33%	450.4 s	1.51	0.02	1.07	0.00	0.00
Cluster 4	544	2.72%	485.6 s	1.34	1.06	0.33	0.00	0.00

- Mô tả đặc trưng kỹ thuật từng cụm:
- Cluster 0 (1.882 mẫu – 9.41%): Số lần click/chuyển phòng cao nhất hệ thống (2.37 lần/phần), thời gian xem trung bình (198.2 giây), hoàn toàn không có tương tác thích, bình luận hay tặng quà (đặc trưng nhóm người xem khám phá nội dung).
 - Cluster 1 (16.824 mẫu – 84.12%): Chiếm đại đa số tập dữ liệu. Thời lượng xem rất ngắn (47.7 giây), click đúng 1 lần (1.00) và bằng 0 ở tất cả các hành vi tương tác (đặc trưng nhóm người xem vãng lai, thụ động, tương ứng 100% nhãn Low ở Bài 2).
 - Cluster 2 (284 mẫu – 1.42%): Thời lượng xem vượt trội nhất (706.7 giây, tương đương gần 12 phút), là cụm duy nhất phát sinh tặng quà với giá trị trung bình 66.44 điểm, đồng thời kết hợp bình luận (0.64) và like (0.48) rất cao (nhóm người ủng hộ VIP).
 - Cluster 3 (466 mẫu – 2.33%): Thời lượng xem dài (450.4 giây), đặc trưng nổi bật nhất là chỉ số thả tim cực cao (trung bình 1.07 like/phần), rất ít bình luận (0.02) và không tặng quà (nhóm người xem tương tác like).
 - Cluster 4 (544 mẫu – 2.72%): Thời lượng xem dài (485.6 giây), đặc trưng bởi tần suất bình luận cao nhất hệ thống (trung bình 1.06 comment/phần), kết hợp thả tim vừa phải (0.33) và không tặng quà (nhóm người xem trò chuyện, giao lưu).

7. KẾT LUẬN

Bài thực hành số 4 đã ứng dụng hoàn chỉnh các kỹ thuật gom cụm dữ liệu không giám sát trên bộ dữ liệu KuaiLive gồm 20.000 bản ghi người xem livestream. Sau các bước tiền xử lý khử phân phối lệch bằng log1p và chuẩn hóa thang đo bằng StandardScaler, nhóm đã thử nghiệm thành công hai thuật toán đại diện: K-Means (thuật toán phân vùng) và DBSCAN (thuật toán dựa trên mật độ). Quá trình khảo sát khoa học qua phương pháp Elbow và Silhouette Score đã xác định cấu hình K = 5 là tối ưu nhất cho K-Means với Inertia = 36.197,49, Silhouette Score đạt đỉnh 0.6742 và Davies-Bouldin đạt 0.7337. Trong khi đó, DBSCAN với cấu hình ε = 0.8, min_samples = 50 đã tách thành 7 cụm mật độ và bóc tách thành công 641 điểm nhiễu (chiếm 3.20%) với Silhouette Score đạt 0.6586 và Davies-Bouldin Score đạt 0.6012.

Về mặt kỹ thuật, K-Means cho kết quả phù hợp hơn cho bài toán phân khúc toàn diện vì phân loại được 100% người dùng, phân tách sắc nét 5 nhóm hành vi có ý nghĩa trực tiếp đối với bài toán tối ưu hóa gợi ý phòng phát sóng. Hạn chế kỹ thuật của phương pháp nằm ở tính chất phân phối dữ liệu gốc quá thưa thớt (sparse) khiến cụm người xem vãng lai chiếm tỷ trọng chi phối lớn (>84%), thuật toán K-Means phụ thuộc vào giả định cụm hình cầu, và không gian chiếu PCA 2D nén khoảng 38.3% phương sai dữ liệu. Tuy vậy, các kết quả định lượng đạt được hoàn toàn đáp ứng xuất sắc các tiêu chí kỹ thuật của môn học và cung cấp nền tảng vững chắc cho đề án cuối kỳ.